



同濟大學

TONGJI UNIVERSITY

专业型硕士研究生学位论文选题报告及工作计划

课 题 名 称	基于聚类的自动驾驶路测关键场景识别研究
学 号	2440761
研 究 生	孙涵
专 业	工程管理
领 域	智能网联汽车
所 在 院 系	经济与管理学院
导 师	魏可信
副 导 师	孙敏
选 题 时 间	2025 年 12 月

同济大学研究生院

2025 年 1 月 24 日

1. 研究问题

1) 研究背景

随着自动驾驶技术的不断发展,基于大规模道路测试数据对系统安全性和鲁棒性进行验证,已成为自动驾驶系统研发和工程落地过程中不可或缺的重要环节。在实际工程中,自动驾驶车辆通过长时间、多场景的道路测试不断积累海量测试数据,用以发现系统潜在缺陷并指导算法优化。

然而,随着测试里程和测试规模的持续扩大,路测数据量呈现爆发式增长,其中绝大多数为驾驶行为稳定、交互关系简单的常规场景,而真正可能暴露系统安全风险或性能瓶颈的场景在整体数据中占比极低,呈现明显的长尾分布特征。这类场景通常伴随复杂交通交互、异常驾驶行为或潜在高风险因素,对自动驾驶系统的安全验证和性能评估具有更高的工程价值。

在现有自动驾驶测试流程中,高价值场景的识别主要依赖测试人员基于经验的人工筛选或基于预设规则的触发机制。一方面,人工分析方式效率低、成本高,难以适应测试数据规模持续增长的现实需求;另一方面,基于规则的方法依赖先验假设,容易遗漏工程人员事先未明确预料的潜在风险场景,导致关键问题发现滞后。

从工程管理和测试流程角度看,测试资源(如人工分析时间、仿真重构资源和回归测试算力)通常是有限的。如果无法对海量路测数据进行有效筛选和优先级排序,高价值场景极易被淹没在大量常规数据中,直接制约测试效率和问题发现能力。因此,如何在无需大量人工标注的前提下,从大规模自动驾驶路测数据中自动识别对系统安全性和性能验证具有重要意义的关键场景,并为工程测试提供可执行的筛选与排序依据,已成为当前自动驾驶测试与评估体系中亟需解决的关键工程问题。

2) 选题依据

在上述研究背景下,从自动驾驶系统的企业研发和工程实践角度进一步分析,大规模道路测试虽然能够覆盖真实交通环境中的多样化场景,但也面临着测试成本高、数据分析压力大以及问题发现周期长等现实瓶颈。随着测试车辆数量和测试里程的持续增长,路测相关的人力、时间和管理成本不断上升,而测试数据的分析效率却难以同步提升。

在实际工程中,自动驾驶系统的失效或性能不足往往并非出现在高频的常规驾驶场景中,而是隐藏在少量具有复杂交互关系、异常行为或潜在高风险特征的场景中。如果无法及时识别并优先分析这些场景,不仅会延长问题暴露和修复周期,还可能导致测试资源被大量消耗在信息价值有限的常规数据上,影响整体研发效率。

近年来,机器学习方法在大规模数据分析和模式挖掘领域得到广泛应用,其中无监督学习方法因其无需人工标注、能够从海量数据中自动挖掘潜在结构特征,在自动驾驶工程实践中展现出显著优势(Kim et al., 2020; Riedmaier et al., 2020; Nalic et al., 2020):其不依赖人工标注和先验规则,能够直接作用于海量未标注路测数据,有助于发现工程人员事先未明确定义的潜在场景模式;同时,其数据驱动的分析方式适合规模化处理,能够与自动驾驶路测数据持续增长的趋势相匹配。此外,无监督学习方法具有较好的可复现性和自动化潜力,

能够与现有自动驾驶测试数据处理流程相结合，为测试流程优化提供技术支撑（Guo et al., 2022; Sun et al., 2021）。

为符合中文学位论文写作规范并与领域通行表述保持一致，本文将自动驾驶测试中对系统安全性与性能验证具有显著影响、需要优先识别与分析的一类场景统一称为关键场景。该概念在国内相关研究中常以“安全关键场景”表述，并与国际研究中的 critical scenario 或 safety-critical scenario 在内涵上保持一致，强调其在测试与安全评估中的高价值意义。本文所研究的关键场景涵盖稀有场景、异常场景以及具有潜在高风险特征的高价值测试场景，与工程实践中常用的 corner case、bad case 等概念在研究对象上具有一致性。

3) 研究目标

在明确自动驾驶测试过程中关键场景筛选与优先级排序这一工程需求的基础上，本文围绕“如何在无需人工标注的前提下，从大规模路测数据中高效识别具有工程价值的关键场景”这一核心问题展开研究，主要研究内容包括以下几个方面：

（1）自动驾驶场景级特征构建方法研究

结合自动驾驶路测数据特点，面向工程应用需求，从车辆自身运动状态、交通环境与密度、潜在风险特征、交通参与者结构以及地图语义等多个维度构建场景级特征表示。在保持计算效率和可解释性的前提下，通过统计特征与关键事件触发型特征相结合的方式，增强对复杂交互和高风险行为的刻画能力，为后续无监督分析提供基础。

（2）基于无监督聚类的场景结构分析方法研究

在构建场景级特征的基础上，引入无监督聚类方法对大规模场景数据进行分析，挖掘数据中潜在的场景结构和模式分布特征。通过聚类结果对场景进行初步分组，识别高频常规场景与低频稀有场景，为关键场景的进一步筛选提供数据驱动的结构依据。

（3）面向工程筛选的关键场景评分与排序机制设计

针对仅依赖聚类结果难以直接指导工程测试的问题，构建综合考虑场景稀有性、簇内异常程度以及风险特征水平的关键场景评分机制。通过对多维指标进行融合，对场景进行排序和优先级划分，为测试人员在有限资源条件下优先分析高价值场景提供参考依据。

（4）基于真实路测数据的实验验证与分析

nuScenes 数据集由 Aptiv 和 Motional 发布，包含多城市、多交通参与者类型和复杂交通交互的真实道路测试数据，已被广泛用于自动驾驶场景分析、行为建模与安全研究，是当前学术界和工程领域中具有代表性的自动驾驶场景数据集之一。

在实验设计中，本文以场景级特征为分析对象，首先对场景聚类结果的结构合理性和分布特征进行分析，以验证无监督聚类方法在刻画场景差异性和长尾分布特征方面的有效性；随后，结合关键场景评分结果，对高分场景进行人工抽检与定性分析，从工程测试视角评估所识别场景的实际分析价值。

通过上述实验与分析,验证所提出方法在无需人工标注条件下,对自动驾驶路测数据中关键场景进行筛选与优先级排序的可行性与工程适用性。

4) 专业理论意义及实际应用价值

(1) 工程应用意义

从自动驾驶系统工程测试的角度看,本文研究的关键场景识别方法有助于缓解当前路测数据规模快速增长与人工分析能力有限之间的矛盾。通过在无需人工标注的前提下对海量路测数据进行自动分析和排序,可减少测试人员在常规场景上的无效投入,引导有限测试资源优先用于具有潜在安全风险或性能价值的关键场景分析,从而提升整体测试效率。

此外,所提出的方法具有较好的工程可扩展性,能够作为自动驾驶测试流程中的前置筛选模块,与现有的数据处理、仿真重构和回归测试流程相结合,为构建数据驱动的测试闭环提供支撑。这对于降低测试成本、缩短问题发现周期具有积极意义。

(2) 研究与方法意义

在研究层面,本文从工程实践需求出发,将无监督学习方法引入自动驾驶场景级分析问题,探索在缺乏人工标注条件下对关键场景进行系统化识别和排序的可行路径。通过将场景稀有性、异常性与风险特征进行综合建模,丰富了自动驾驶场景分析和关键场景识别的研究思路。

同时,本文以场景级表示为基础,在保证方法简洁性和可解释性的前提下,构建了一套可操作的分析流程,为后续在不同数据集或工程场景中开展类似研究提供了方法参考。

2. 文献综述（不得少于 2000 字）

1) 自动驾驶测试与关键场景研究现状

自动驾驶测试研究普遍认为，关键场景的发现是保障自动驾驶系统安全性的重要前提（Kalra & Paddock, 2016; Koopman & Wagner, 2017）。相关研究指出，自动驾驶系统的失效风险往往集中于少量具有复杂交互关系或极端行为特征的场景中，而非均匀分布于所有测试数据中（Koopman & Wagner, 2017; Riedmaier et al., 2020）。

在已有研究中，关键场景的定义方式主要包括基于规则的判定方法、基于风险指标的方法以及基于异常检测的统计方法（Chandola et al., 2009; Aggarwal, 2017）。然而，单一方法往往难以全面覆盖复杂交通环境中的多样化风险场景，限制了其在工程实践中的应用效果（Riedmaier et al., 2020; Nalic et al., 2020）。

2) 自动驾驶场景表示与特征构建方法研究

在自动驾驶场景分析研究中，如何对复杂、多源的原始数据进行有效表示，是后续分析和建模的基础问题。已有研究普遍认为，合理的场景表示方式不仅直接影响分析结果的有效性，也关系到方法在工程实践中的可实施性和可扩展性（Riedmaier et al., 2020; Bagschik et al., 2018）。

从数据粒度角度看，现有自动驾驶场景表示方法大致可分为帧级表示、片段级表示和场景级表示三类。帧级表示通常以单一时间帧的状态或传感器信息作为分析对象，能够刻画瞬时驾驶行为，但在大规模路测数据中易受噪声干扰，且难以反映完整驾驶过程的整体特征（Feng et al., 2021; Zofka et al., 2016）。片段级表示通过对连续时间窗内的数据进行建模，在一定程度上增强了时序信息表达，但仍存在时间窗口选取依赖经验、工程实现复杂等问题（Bagschik et al., 2018; Ulbrich et al., 2015）。

近年来，越来越多研究开始关注场景级表示方法，即以完整驾驶场景作为分析单元，对场景内多帧数据进行统计与聚合，从而形成反映整体交通环境和驾驶行为特征的高层次表示。相关研究指出，场景级表示在降低数据规模的同时，能够保留交通交互和驾驶行为的整体结构特征，更适合工程测试和离线分析任务（Riedmaier et al., 2020; 余唯之等, 2022; Nalic et al., 2020）。

在场景级特征构建方面，已有研究通常从多个维度对场景进行描述。一类研究关注车辆自身的运动特性，通过速度、加速度和航向变化等指标刻画驾驶行为模式（李克强等, 2021; Zhang et al., 2019）；另一类研究侧重交通环境特征，通过周围车辆数量、交通密度以及交通参与者构成反映场景复杂程度（赵文杰等, 2020; Krajewski et al., 2018）。此外，随着自动驾驶安全研究的深入，引入时间到碰撞（Time To Collision, TTC）等风险相关指标，已成为场景分析中的重要趋势，用于量化场景中潜在的安全风险水平（Koopman & Wagner, 2017; Hayward, 1972）。

从工程实践角度来看，基于统计特征的场景表示方法具有实现简单、计算效率高、可解释性强等优势，适合应用于大规模路测数据的离线分析过程（朱向雷等, 2021; Winner et al., 2016）。相比之下，尽管基于深度学习的端到端场景表示方法在部分研究中展现出较强建模能力，但其对大规模标注数据的依赖以及

模型训练和调参成本较高等问题,限制了其在工程测试流程中的推广应用(冯洋等, 2021; Goodfellow et al., 2016)。

3) 基于聚类的自动驾驶场景分析方法研究

随着自动驾驶测试数据规模的不断扩大,基于聚类的场景分析方法逐渐成为自动驾驶场景理解和分类研究中的重要手段。聚类方法能够在无需人工标注的条件下,根据数据内在结构对场景进行分组,对于挖掘大规模未标注数据中的潜在模式具有重要意义(Kim et al., 2020; Jain, 2010)。

传统聚类方法中,KMeans 和高斯混合模型(GMM)是应用较为广泛的代表性方法。相关研究通常将场景特征映射至特征空间后,利用 KMeans 等传统聚类方法对场景进行聚类,实现对不同驾驶工况的自动分类(周航等, 2021; Xu & Wunsch, 2005)。该类方法实现简单、计算效率高,在自动驾驶场景初步分析和探索性研究中具有一定实用价值(Aggarwal, 2017; MacQueen, 1967)。

然而,传统聚类方法通常需要预先设定聚类数量,并隐含对数据分布形态的假设。例如,KMeans 方法假设簇在特征空间中呈现相对规则的几何结构,对异常样本较为敏感(Aggarwal, 2017; Jain, 2010)。在自动驾驶数据中,场景分布往往呈现明显的非均匀性和长尾特征,不同类型场景的密度差异较大,使得聚类结果对参数选择具有较强依赖性(Guo et al., 2022; Wang & Wang, 2021)。

针对上述问题,近年来基于密度的聚类方法逐渐受到关注。DBSCAN 及其扩展方法 HDBSCAN 通过分析数据在特征空间中的分布密度来识别簇结构,能够自动确定聚类数量,并区分噪声样本(Ester et al., 1996; Campello et al., 2015; McInnes et al., 2017)。相关研究表明,密度聚类方法在处理非均匀分布数据和稀有事件分析任务中具有明显优势,适合应用于自动驾驶场景的异常和关键场景识别(Feng et al., 2021; Guo et al., 2022)。

4) 关键场景识别与评价指标研究

在自动驾驶测试与安全验证研究中,关键场景的识别与评价一直是研究重点之一。由于关键场景具有低频出现、形式多样且难以事先穷举等特点,其定义和识别方式在不同研究中存在一定差异(Riedmaier et al., 2020; Koopman & Wagner, 2017)。

早期研究多采用基于规则的方法对关键场景进行定义,例如通过设置速度、距离或加速度等阈值,识别可能存在安全风险的驾驶场景(Koopman & Wagner, 2017; Hayward, 1972)。该类方法具有实现简单、可解释性强等优点,但通常依赖人工经验进行规则设计,难以覆盖复杂交通环境中的未知风险场景(余唯之等, 2022; Koopman, 2019)。

随着数据驱动方法的发展,基于风险指标的关键场景评价方式逐渐受到关注。其中,时间到碰撞(Time To Collision, TTC)及其衍生指标被广泛用于衡量驾驶场景中的潜在安全风险(Kalra & Paddock, 2016; Elvik, 2015)。然而,已有研究指出,单一风险指标往往只能反映场景的某一侧面,难以全面刻画复杂交通环境中的关键场景特性(Chandola et al., 2009; Rocklage & Fei, 2019)。

近年来,异常检测和稀有事件分析方法逐渐被引入自动驾驶场景分析中,用于从大规模数据中识别偏离常规模式的异常样本(Aggarwal, 2017; Breunig et

al., 2000)。相关研究表明,部分关键场景并非表现为极端风险值,而是由于其行为模式或场景组合的特殊性,在统计意义上偏离主流场景分布(Feng et al., 2021; Guo et al., 2022)。

从工程应用角度看,越来越多研究倾向于采用多因素融合的方式,对关键场景进行综合评价,以提升筛选结果的稳定性和实用性(Riedmaier et al., 2020; Zhao et al., 2018)。此外,在实际测试流程中,相较于对场景进行简单的二分类判定,基于综合指标的排序和优先级评估方式更符合工程实践需求(朱向雷等, 2021; 张立新等, 2023)。

5) 文献评述与小结

综上所述,国内外学者围绕自动驾驶测试、场景分析以及关键场景识别等问题开展了大量研究,在场景建模、无监督学习方法应用及安全风险评估等方面取得了丰富成果(Koopman & Wagner, 2017; Riedmaier et al., 2020)。相关研究为自动驾驶系统的安全验证和测试流程优化提供了重要的理论基础和方法支撑。

现有研究表明,场景级表示方法在工程实践中具有较好的适用性,无监督学习方法能够在缺乏人工标注条件下挖掘大规模数据中的潜在结构特征,为复杂场景分析提供了一种有效手段(Kim et al., 2020)。同时,不同聚类方法在处理自动驾驶场景长尾分布和异常样本方面表现存在差异,其中,基于密度的聚类方法在稀有场景发现和异常样本识别任务中展现出一定优势(Campello et al., 2015)。

在关键场景评价方面,已有研究指出,单一规则或单一风险指标难以满足复杂交通场景分析需求,多因素融合和排序式评价逐渐成为工程实践中的发展趋势(Aggarwal, 2017; 余唯之等, 2022)。该方法更符合实际测试流程中对高价值场景进行优先分析和资源分配的需求。

从功能安全标准角度看,ISO 21448(Safety of the Intended Functionality, SOTIF)进一步指出,自动驾驶系统面临的安全风险不仅来源于已知的功能失效,还包括由于场景覆盖不足或认知能力受限而引发的“未知但潜在不安全场景(Unknown Unsafe Scenarios)”。这类场景通常难以通过基于规则或人工经验的方式事先枚举,是当前自动驾驶测试与验证体系中面临的关键挑战之一。

总体来看,现有研究为自动驾驶场景分析和关键场景识别提供了丰富的方法基础,但在无需人工标注条件下,面向工程应用的场景级自动筛选与优先级排序方法仍有进一步研究空间。基于此,本文从工程实践需求出发,结合无监督学习方法,对大规模路测数据中的场景进行结构化分析,探索将原本处于“Unknown”状态的潜在风险场景逐步转化为“Known”,以期为后续的仿真重构、安全评估及系统优化提供支持。

附：参考文献

序号	文献目录
[1]	Kalra N, Paddock S M. Driving to safety: How many miles of driving would it take to demonstrate autonomous vehicle reliability?[R]. Santa Monica: RAND Corporation, 2016.
[2]	Koopman P, Wagner M. Challenges in autonomous vehicle testing and validation[J]. SAE International Journal of Transportation Safety, 2017, 4(1): 15-24.
[3]	Chandola V, Banerjee A, Kumar V. Anomaly detection: A survey[J]. ACM Computing Surveys, 2009, 41(3): 1–58.
[4]	Riedmaier S, Ponn T, Ludwig F, et al. Survey on scenario-based safety assessment of automated vehicles[J]. IEEE Access, 2020, 8: 87456-87477.
[5]	Kim J, Lee J, Kum D. Unsupervised learning-based scenario classification for autonomous driving[J]. IEEE Transactions on Intelligent Vehicles, 2020, 5(3): 478–489.
[6]	Feng S, Yan X, Sun H, et al. Mining rare events from traffic data for autonomous driving[C]//Proceedings of the IEEE Intelligent Transportation Systems Conference. 2021: 1145–1152.
[7]	Bagschik G, Menzel T, Maurer M. Ontology based scene creation for the development of automated vehicles[C]//Proceedings of the IEEE Intelligent Vehicles Symposium. 2018: 1813–1820.
[8]	余唯之, 苏奕敏, 王琳. 自动驾驶测试评价研究综述[J]. 系统科学与数学, 2022, 42(3): 495 - 508.
[9]	李克强, 王耀南, 王震. 面向自动驾驶的交通场景特征建模方法研究[J]. 汽车工程, 2021, 43(10): 1181 - 1190.
[10]	赵文杰, 刘洋, 马会军. 基于多维交通特征的驾驶场景复杂度评估方法[J]. 交通运输系统工程与信息, 2020, 20(6): 165 - 173.
[11]	Aggarwal C C. Outlier analysis[M]. New York: Springer, 2017.
[12]	Jain A K. Data clustering: 50 years beyond K-means[J]. Pattern Recognition Letters, 2010, 31(8): 651–666.
[13]	Xu R, Wunsch D. Survey of clustering algorithms[J]. IEEE Transactions on Neural Networks, 2005, 16(3): 645–678.
[14]	MacQueen J. Some methods for classification and analysis of multivariate observations[C]//Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. 1967: 281–297.
[15]	Guo J, Zhao D, Peng H. Rare driving scenario identification for autonomous driving[J]. IEEE Access, 2022, 10: 12645–12658.
[16]	Ester M, Kriegel H P, Sander J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]//Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. 1996: 226–231.

[17]	Campello R J G B, Moulavi D, Zimek A, et al. Hierarchical density estimates for data clustering, visualization, and outlier detection[J]. ACM Transactions on Knowledge Discovery from Data, 2015, 10(1): 1–51.
[18]	McInnes L, Healy J, Astels S. hdbscan: Hierarchical density based clustering[J]. Journal of Open Source Software, 2017, 2(11): 205.
[19]	Hayward J C. Near-miss determination through use of a scale of danger[R]. Pennsylvania Transportation Institute, 1972.
[20]	Elvik R. A review of the predictive power of near-misses and conflicts in traffic safety analysis[J]. Accident Analysis & Prevention, 2015, 75: 1–8.
[21]	Rocklage D, Fei Y. Rare event detection and evaluation[J]. Reliability Engineering & System Safety, 2019, 187: 103–112.
[22]	Breunig M M, Kriegel H P, Ng R T, et al. LOF: Identifying density-based local outliers[C]//Proceedings of the ACM SIGMOD International Conference on Management of Data. 2000: 93–104.
[23]	Feng S, Yan X, Sun H, et al. Mining rare events from traffic data for autonomous driving[C]//IEEE ITSC. 2021.
[24]	Zhao D, Lam H, Peng H, et al. Accelerated evaluation of automated vehicles in simulation[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(12): 3997–4007.
[25]	朱向雷, 王海弛, 尤翰墨, 等. 自动驾驶智能系统测试研究综述[J]. 软件学报, 2021, 32(7): 2056 – 2077.
[26]	冯洋, 夏志龙, 郭安, 陈振宇. 自动驾驶软件测试技术研究综述[J]. 中国图象图形学报, 2021, 26(1): 13 – 27.
[27]	Zhang L, Chen Z. Risk evaluation of autonomous driving test scenarios[J]. Systems Engineering—Theory & Practice, 2023.
[28]	ISO 26262:2018. Road vehicles—Functional safety[S].
[29]	ISO 21448:2022. Road vehicles—Safety of the intended functionality (SOTIF)[S].
[30]	SAE J3016:2021. Taxonomy and definitions for terms related to driving automation systems[S].
[31]	GB/T 44464—2024. 智能网联汽车 自动驾驶数据记录系统[S]. 北京: 中国标准出版社, 2024.
[32]	GB/T 44719—2024. 智能网联汽车 自动驾驶功能道路试验方法及要求[S]. 北京: 中国标准出版社, 2024.
[33]	ISO/TR 4804:2020. Road vehicles—Safety and cybersecurity for automated driving systems[S].
[34]	Russell S, Norvig P. Artificial Intelligence: A Modern Approach[M]. Pearson, 2010.
[35]	Bishop C M. Pattern Recognition and Machine Learning[M]. Springer, 2006.
[36]	Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning[M]. Springer, 2009.

[37]	Murphy K P. Machine Learning: A Probabilistic Perspective[M]. MIT Press, 2012.
[38]	Goodfellow I, Bengio Y, Courville A. Deep Learning[M]. MIT Press, 2016.
[39]	Chen L, He Y, Whangbo T. Driving scenario complexity analysis[J]. IEEE Access, 2021.
[40]	Wang Y, Wang Z. Clustering-based driving scenario mining[J]. IEEE ITSC, 2021.
[41]	Gyllenhammar M, Johansson R, Warg F, et al. Towards an operational design domain taxonomy[J]. IEEE IV, 2020.
[42]	Nalic D, Eichberger A, Hanzl C, et al. Scenario-based testing of automated driving systems: A literature survey[J]. IEEE Access, 2020.

3. 研究内容

1) 研究对象

本文以自动驾驶系统在实际道路测试过程中产生的大规模路测数据为研究对象，重点关注其中对系统安全性与性能验证具有重要意义的关键场景。关键场景是指在整体路测数据中出现频率较低，但往往伴随复杂交通交互、异常驾驶行为或潜在高风险特征的场景类型，是自动驾驶测试与评估过程中需要重点识别和优先分析的对象。

从数据形态上看，自动驾驶路测数据具有规模大、时序性强、场景类型分布不均衡等特点，其中大量常规场景与少量关键场景并存，呈现明显的长尾分布特征。本文将路测数据按照场景（scene）级别进行组织和分析，以完整驾驶片段作为基本分析单元，对场景内多帧信息进行聚合与建模，从而避免帧级分析在工程实践中带来的数据冗余和噪声干扰问题。

在具体实验中，本文选取公开自动驾驶数据集 nuScenes 作为研究数据来源，对其中包含的多类真实交通场景进行分析与验证，以评估所提出方法在实际自动驾驶测试场景筛选任务中的工程适用性。

2) 研究内容

围绕自动驾驶测试过程中关键场景识别这一工程需求，本文结合无监督学习方法，开展以下几个方面的研究工作：

（1）自动驾驶场景级特征构建方法研究

针对原始自动驾驶路测数据粒度较细、直接分析难度较大的问题，本文首先开展自动驾驶场景级特征构建方法研究。以自动驾驶数据中的“场景”为基本分析单元，对场景内多帧数据进行统计与聚合，形成能够反映整体驾驶环境特征的场景级表示。

在实际道路测试中，一个完整场景通常对应一段具有明确交通语义和驾驶目标的连续驾驶过程，例如城市道路中车辆通过信号灯控制的交叉口场景、多车密集跟驰条件下的拥堵行驶场景，以及伴随行人或非机动车横穿的复杂混合交通场景等。这类场景往往包含多帧连续的车辆运动与交通交互信息，仅依赖单帧数据难以全面刻画其整体特征。

因此，本文通过对场景内多帧数据进行统计与聚合，在保持场景整体结构和交通交互特性的同时，有效降低数据冗余和噪声干扰，为后续基于无监督学习的场景结构分析和关键场景识别提供稳定、可分析的特征基础。

在特征构建过程中，综合考虑车辆自身运动状态、交通环境复杂性、交通参与者构成以及潜在安全风险等因素，设计并提取了一系列具有工程意义的统计特征，该类特征在自动驾驶场景建模和测试场景分析中已被广泛采用（Riedmaier et al., 2020; Caesar et al., 2020; 周航等, 2021），实现从高频、冗余的帧级数据向结构化、可分析的场景级特征的转化，为后续无监督学习分析提供基础。

（2）基于无监督学习的自动驾驶场景聚类分析方法研究

在完成场景级特征构建的基础上，本文进一步开展基于无监督学习的自动

驾驶场景聚类分析研究。考虑到实际工程中缺乏大规模人工标注数据的现实约束，本文采用无监督学习方法对场景进行聚类分析，以挖掘路测数据中潜在的场景类型和结构模式。

通过对场景特征进行预处理、标准化及降维操作，在降低特征维度的同时尽量保留场景之间的相对相似性结构；随后，采用基于密度的聚类方法对场景进行自动聚类，实现对不同驾驶场景类型的划分。该过程无需预先定义场景类别数量，能够较好地适应自动驾驶数据中场景分布复杂、长尾特征明显的特点。

（3）无监督聚类参数选择与稳定性分析方法研究

针对无监督聚类方法对参数设置较为敏感的问题，本文进一步对聚类过程中关键参数的选择开展系统性分析。通过构建参数组合空间，对不同参数设置下的聚类结果进行对比，从聚类数量、噪声样本比例以及聚类结果稳定性等角度对结果进行综合评估。

在此基础上，选择在多项评价指标上表现相对稳定的参数组合作为最终聚类配置，以减少参数主观选择对聚类结果的影响，提高聚类分析结果在工程应用中的可靠性。

（4）面向工程应用的关键场景评分与筛选方法研究

为避免仅依据聚类结果对关键场景进行简单判定，本文在聚类分析基础上进一步研究面向工程应用的关键场景评分与筛选方法。结合自动驾驶测试实践需求，从场景稀有性、簇内异常程度以及风险特征水平等多个维度，对场景进行综合评价。

通过构建多因素融合的关键场景评分指标，对场景进行排序和优先级划分，使测试人员能够在有限时间和资源条件下，优先关注具有潜在工程价值和安全隐患的场景，从而提高测试分析效率并支撑测试资源的合理分配。

（5）基于开源数据集的实验验证与分析

为验证所提出方法的有效性，本文基于开源自动驾驶数据集开展实验研究。通过对真实自动驾驶场景数据的处理与分析，从聚类结果合理性、关键场景分布特征以及评分排序结果等方面对方法效果进行验证。

同时，通过对不同类型场景的对比分析，探讨所提出方法在实际工程应用中的适用性与局限性，为后续方法改进和工程推广提供参考。

3) 研究大纲

围绕上述研究内容，本文的整体结构安排如下：

第一章 绪论

1.1 研究背景及研究意义

1.1.1 研究背景

1.1.2 研究意义

1.2 研究内容及研究方法

1.2.1 研究内容

1.2.2 研究方法

1.2.3 技术路线

1.3 研究创新点

第二章 自动驾驶关键场景识别相关研究综述与理论基础

2.1 自动驾驶测试与关键场景研究现状

2.2 自动驾驶场景表示与特征构建方法研究

2.3 基于聚类的自动驾驶场景分析方法研究

2.4 关键场景发现与评价指标研究

2.5 本章小结

第三章 自动驾驶路测数据中的关键场景识别问题分析

3.1 自动驾驶路测数据特征与工程挑战分析

3.1.1 路测数据规模与分布特征

3.1.2 关键场景的长尾分布特性

3.2 工程测试流程中的关键场景筛选需求分析

3.2.1 现有测试流程与数据处理方式

3.2.2 测试资源约束与分析效率问题

3.3 无监督学习在关键场景识别中的应用需求分析

3.4 本章小结

第四章 自动驾驶场景级特征构建与无监督聚类方法

4.1 场景级分析单元与数据组织方式

4.2 自动驾驶场景级特征构建方法

4.2.1 车辆运动特征

4.2.2 交通环境与密度特征

4.2.3 潜在风险特征

4.3 场景特征预处理与降维方法

4.4 无监督聚类方法选择与对比分析

4.4.1 聚类方法选择依据与工程考虑

4.4.2 典型划分式聚类方法的应用分析

4.4.3 基于密度的层次聚类方法的应用分析

4.4.4 不同聚类方法的对比与工程适用性分析

4.5 聚类参数选择与稳定性分析方法

4.6 本章小结

第五章 面向工程应用的关键场景评分方法

5.1 关键场景筛选的工程需求分析

5.2 关键场景综合评分与排序机制设计

5.2.1 场景稀有性指标设计

5.2.2 聚类结果的异常程度度量

5.2.3 风险特征融合与综合评分方法

5.3 关键场景评分机制的工程解释性与使用方式分析

5.4 本章小结

第六章 实验设计与关键场景识别效果验证

6.1 实验设计与数据集说明

6.2 聚类结果分布与稳定性分析

6.3 关键场景识别与排序效果分析

6.4 工程应用有效性与人工抽检分析

6.5 本章小结

第七章 结论与展望

7.1 研究结论

7.2 研究展望

4. 研究方法及技术路线


1) 研究方法

本研究采用无监督学习方法对自动驾驶场景进行分析与建模,整体研究方法以“场景特征构建—无监督聚类—关键场景的评分与筛选”为主线,面向工程实践需求,构建一套无需人工标注、可应用于大规模路测数据分析的场景级关键场景识别方法。

在研究过程中,首先从自动驾驶场景数据中提取能够反映交通参与者行为、车辆动态特性以及潜在风险因素的场景级特征;随后,利用无监督学习方法对场景特征进行聚类分析,以挖掘数据中潜在的场景模式和结构;在此基础上,结合场景稀有性、簇内异常程度以及风险特征,构建用于工程筛选的关键场景评分机制,实现对高价值场景的自动识别与排序。

2) 技术路线

(1) 整体技术路线描述



本研究的技术路线如图所示，整体流程可分为以下几个主要步骤：

（1）基于自动驾驶场景数据，按照场景维度对车辆运行状态、交通参与者信息及地图语义信息进行统计与聚合，构建场景级特征表示；

（2）对提取的场景特征进行预处理与标准化，并通过降维方法在保持场景局部结构特性的同时，降低特征维度，为后续聚类分析提供合适的特征空间；

（3）采用基于密度的无监督聚类方法对场景进行聚类分析，自动识别具有相似特征分布的场景类型，并区分常规场景与稀有场景；

（4）在聚类结果基础上，从场景稀有性、簇内异常程度以及风险特征等多个维度构建关键场景评分指标，对场景进行综合评价与排序，从而实现对潜在高价值关键场景的识别

（2）场景级特征构建方法

在场景级特征构建阶段，本研究以自动驾驶数据中的“场景（scene）”作为分析单位，对场景内多个时间帧的信息进行统计与聚合，形成能够反映整体驾驶环境特征的场景级特征向量。已有研究表明，场景级表示方法在自动驾驶测试与分析中具有较好的工程可操作性，能够在降低数据规模的同时保留关键交通交互特征（Riedmaier et al., 2020）。

特征设计主要从以下几个方面展开：

（1）车辆自身运动特征：

包括自车速度、纵向与横向加速度以及航向变化等统计指标，用于描述自车在不同场景中的驾驶行为特性。相关研究指出，车辆运动状态是刻画驾驶行为差异和场景类型的重要基础特征，广泛应用于自动驾驶行为分析和场景分类研究中（Kim et al., 2020）。

（2）交通环境与密度特征：

包括周围车辆数量、速度分布以及交通参与者密度变化情况，用于刻画场景的交通复杂程度。已有研究表明，交通密度及其变化特征与场景复杂性和驾驶决策难度密切相关，是衡量交通场景复杂度的重要指标（赵文杰等，2020）。

（3）潜在风险特征：

引入最小碰撞时间（Time To Collision, TTC）及其相关统计指标，用于反映场景中可能存在的安全风险水平，该类指标已被广泛用于交通安全分析和自动驾驶风险评估研究中（Hayward, 1972; Kim et al., 2020; 余唯之等，2022），能够有效反映车辆间交互的紧急程度。

（4）交通参与者结构特征：

统计大型车辆、非机动车及行人的出现比例，以描述不同场景中交通参与者的构成差异。相关研究指出，不同类型交通参与者的组合形式会显著影响场景的复杂性和潜在风险，是场景分析中不可忽视的重要因素（Riedmaier et al., 2020）。

(5) 地图语义特征:

结合地图信息,提取交叉口、人行横道等与驾驶复杂性密切相关的环境语义特征,以增强对不同交通工况的区分能力(Caesar et al., 2020; Guo et al., 2022)。已有研究和行业标准均表明,道路结构和语义信息在场景定义与安全分析中具有重要作用,是构建场景库和开展场景化测试的重要依据(GB/T 41789—2022; ISO 21448:2022)。通过上述多维度特征的综合构建,使得场景级特征既能够反映交通环境的整体结构,又具备一定的风险敏感性,为后续无监督聚类与关键场景分析提供基础。

(3) 无监督聚类方法选择

在场景聚类阶段,本研究采用基于降维与密度聚类相结合的无监督学习方法。首先,利用非线性降维方法对高维场景特征进行映射,在保留场景局部相似结构的同时降低特征维度;随后,在降维后的特征空间中采用基于密度的聚类算法对场景进行聚类分析。

相较于需要预先指定簇数量的传统聚类方法,基于密度的聚类方法能够根据数据分布特性自动确定簇结构,并具备识别噪声样本的能力,更加符合自动驾驶场景数据中“长尾分布”和“稀有场景占比低”的特点。因此,该方法在工程实践中更适用于识别潜在的关键场景。

(4) 关键场景评分与筛选机制

为避免仅依据聚类结果对关键场景进行简单判定,本研究在聚类分析基础上进一步构建了用于工程筛选的关键场景评分机制。该评分机制综合考虑以下三个方面:

(1) 场景稀有性:通过场景所属聚类的规模衡量该类场景在整体数据中的出现频率,簇规模越小,其对应场景的稀有性越高。已有研究表明,自动驾驶测试中的高风险或高价值场景通常呈现长尾分布特征,低频场景往往具有更高的分析价值(Koopman & Wagner, 2017; Sun et al., 2021);

(2) 簇内异常程度:衡量单个场景在其所属聚类内部与典型场景的偏离程度,用于识别同类场景中具有极端行为特征的异常样本,该思想与异常检测中“类内异常”分析的基本理念一致(Aggarwal, 2017; Chandola et al., 2009);

(3) 风险特征水平:结合与安全相关的场景特征,对场景中潜在风险程度进行量化,以避免仅依据统计分布特性筛选场景而忽视具有明确安全隐患的关键工况(Kim et al., 2020; Guo et al., 2022);

上述指标分别从场景稀有性、异常性以及潜在风险水平等角度对关键场景进行刻画,形成多维度互补的评价体系,有助于提升关键场景筛选结果在工程应用中的可信度和可解释性(Riedmaier et al., 2020; Sun et al., 2021)。

3) 关键技术或难点

本研究的关键技术与难点主要体现在以下几个方面:

(1) 如何在不依赖人工标注的条件下,构建能够反映自动驾驶场景复杂性和风险特征的场景级特征表示;

（2）如何在高维、多尺度的场景特征空间中，选择合适的无监督学习方法，以有效刻画场景之间的相似性与差异性；

（3）如何在无监督聚类结果基础上，设计具有工程可解释性的关键场景评价指标，使其能够为实际测试流程提供决策支持。

5. 可行性分析与研究基础

1) 可行性分析

本研究围绕自动驾驶大规模路测数据中场景级关键场景的识别问题展开,从研究条件、技术方法及数据资源等方面具备较高的可行性。

首先,在研究条件方面,本文所采用的无监督学习方法无需依赖大量人工标注数据,能够直接作用于现有的自动驾驶路测数据,符合当前工程实践中数据获取和标注成本较高的实际情况;同时,相关算法和工具链较为成熟,具备良好的工程可实现性。

其次,在技术方法方面,本文提出的研究流程以场景特征构建、无监督聚类 and 关键场景评分为核心,各环节之间逻辑清晰、实现路径明确,能够逐步完成从原始数据到场景筛选结果的转化,整体技术路线具备较强的可操作性和可扩展性。

最后,在数据资源方面,本文基于公开的自动驾驶数据集开展研究,数据规模充足、场景类型丰富,能够覆盖多种典型与复杂驾驶工况,为方法验证和实验分析提供了可靠的数据基础。

2) 研究基础

(1) 数据与实验基础

在研究基础方面,本文已完成基于开源自动驾驶数据集的实验环境搭建和数据处理工作。通过对 850 个自动驾驶场景的数据进行解析和整理,构建了场景级特征数据集,为后续无监督聚类 and 关键场景分析提供了基础数据支撑。

目前已完成对数百个自动驾驶场景的特征提取和统计分析,涵盖车辆运动状态、交通环境特征、潜在风险指标以及地图语义信息等多个维度,实验流程已在实际数据上验证可行,具备继续深入分析和扩展研究的条件。

(2) 方法与工具基础

在方法与工具方面,本文已完成无监督聚类分析及相关参数配置的实验探索。通过构建完整的数据预处理、特征降维、聚类分析及结果评估流程,实现了自动驾驶场景的无监督聚类与分类分析。

同时,针对无监督方法参数敏感性问题,已开展系统性的参数组合测试与稳定性分析,为后续实验中参数选择提供了依据。相关算法与分析流程均基于成熟的开源机器学习工具实现,具有良好的可复现性和工程推广潜力。

(3) 前期研究成果

在前期研究过程中,本文已初步实现基于无监督学习的自动驾驶场景聚类分析,并在此基础上构建了多因素融合的关键场景评分机制。通过对聚类结果 and 评分结果的分析,能够较为直观地区分常规场景与具有潜在分析价值的复杂场景,验证了研究思路的合理性。

上述前期研究为本文后续进一步完善方法、开展对比实验以及进行深入分析奠定了良好基础,降低了研究过程中的不确定性风险。

6. 预期成果

本研究围绕自动驾驶大规模路测数据中场景级关键场景的识别问题,预期形成以下研究成果:

- (1) 构建一套面向自动驾驶工程测试流程的场景级特征构建方法,实现对原始路测数据的结构化表达;
- (2) 提出一套基于无监督学习的自动驾驶场景聚类分析流程,能够在无需人工标注的条件下对大规模场景数据进行分类与分析;
- (3) 设计一套融合场景稀有性、簇内异常程度及风险特征的关键场景评分与筛选机制,为工程测试人员提供可执行的场景优先级排序依据;
- (4) 基于开源自动驾驶数据集对所提出方法进行实验验证,并通过对比分析探讨不同聚类方法在场景分析任务中的适用性;
- (5) 形成一篇完整的硕士学位论文,总结研究方法、实验结果及工程应用价值,为后续自动驾驶测试流程优化提供参考。

8. 同济大学硕士研究生学位论文选题报告评分表

评审项目	权重	评分标准		得分（百分制）
A.研究问题	30%	80~100 分	研究问题明确，具有前沿性，反映出明确的应用研究中的科学内涵，具有较强的应用价值。	
		60~80 分	研究问题明确，反映出应用研究中的科学内涵，具有应用价值。	
		60 分以下	研究问题不明，缺乏理论意义和实用价值。	
B.理论基础和专门知识	20%	80~100 分	较好地掌握并能综合运用科学理论、方法和技术手段解决研究问题。	
		60~80 分	基本掌握理论基础和系统专业知识。	
		60 分以下	缺乏理论基础和系统知识。	
C.工作成果	20%	80~100 分	成果科学、完整、扎实，体现出明确的学术思想。	
		60~80 分	研究成果完整，体现出一定的学术思想。	
		60 分以下	研究成果不完整，未体现学术观点。	
D.工作方法	20%	80~100 分	工作方法科学合理，条理清楚，针对性强。	
		60~80 分	制定了明确的工作方案，有针对性。	
		60 分以下	研究方法不明确。	
E.报告报告	10%	80~100 分	报告严密、逻辑性强、文笔流畅，表达清楚。	
		60~80 分	基本概念清晰、层次分明，表达较清楚。	
		60 分以下	写作、表达较差。	
总分		总分=0.3A+0.2B+0.2C+0.2D+0.1E		

备注：评审专家只对五项指标每一项的最后一栏内打分（百分制），不必计算总分。

评审小组组成：

组成	姓名	职称	单位	签字
导师				
成员	熊焰	教授	上海应用技术大学	
	王洪伟	教授	同济大学经济与管理学院	
	王世进	副教授	同济大学经济与管理学院	

注：此评分表作为硕士研究生课程成绩单必备的材料之一